

FET445 Veri Madenciliđi

Kütüphanede okuyucuların bir
sonraki kitabı tahminleme

Grup: Kütüphane Zekası

Tarih:

21.12.2025

Kütüphanede okuyuculara kitap tavsiyesi

Kütüphanelerde bir çok kitap bulunmakta ve okuyucular bunlara karar vermekte zorlanmaktadır veya kütüphane görevlileri okuyucuların ilgilerini çekebilmek ve okuyucu kaybetmek istememektedir.

Biz iste bu problemi okuyucuların bilgilerine ve son okuduğu kitaplara bakarak bir sonraki hangi kitabı alacağını tahminlemekteyiz.



Veri seti -> Veri setimiz türkiyenin en büyük üniversite kütüphanesine sahip İstanbul Medeniyet Üniversitesi Ziraat Bankası Kütüphanesinin veri setidir. Gerçek bir veri setidir.


Size -> 6 Sütun 13437 satır

Özellik Tipi -

<u>Özellik</u>	<u>Tip</u>
<i>Öğrenci-Kimlik-no</i>	ID
<i>Cinsiyet</i>	Kategorik
<i>Fakülte</i>	Kategorik
<i>Bölüm</i>	Kategorik
<i>Kitap-Id</i>	Kategorik
<i>Lc_Kategori</i>	Hedef Değişken(Kategorik)

Veri setimizde LC_kategori denegesiz olduğunu rahatlıkla görebiliyoruz.

Dil ve Edebiyat	24.367371
Tıp	20.117595
Hukuk	7.561774
Siyaset Bilimi	7.450134
Felsefe, Psikoloji, Din	7.182197
Bilim	7.122656
Güzel Sanatlar	7.085442
Eğitim	6.795177
Sosyal Bilimler	6.728193
Diğer(müzik ,askerlik toplam) 10..	



LC_Kategori hedef değişkeninin sınıf dağılımı incelendiğinde, bazı kitap kategorilerinin veri setinde baskın olduğu, bazı kategorilerin ise oldukça az sayıda örnek içerdiği görülmüştür.

Bu durum veri setinin **belirgin şekilde dengesiz (imbalanced)** olduğunu göstermektedir.

Çözümü:

Bu durumu ise `class_weight = 'balanced'` ağırlık vererek çözdük. Çok veriye düşük ve az veriye yüksek ağırlık verdik yani model sadece Dil ve Edebiyat veya Tıp demeye yönelmesin diye.

Temel feature engineering -> Kategorik değişkenleri kodlama (label encoding).
Çok sınıflı hedef değişken sayısallaştırıldı (target encoding)
Öğrencinin kaç kitap okudu eklendi -> (Derived Feature)

Feature extraction teknikleri -> Her öğrenci için tek bir satır (Wide format dönüşümü)
Sıralı okuma bilgisi (1-3).

Train -test split oranı -> %80 eğitim % 20 test olarak ayrılmıştır modelin objektif tahminleme yapabilmesi için

Performance metrikler nelerdir? Accuracy -> modelin gerçek doğruluğu

F1 score -> Dengesiz veri seti nedeniyle model performansı için F1 score kullanıldı

Precision -> Modelin pozitif dediği tahminlerin nekadarı doğru

Best Model 1: XGBoost

Model geliştirme sürecinde veri ön işleme , özellik çıkarımı(feature extraction), özellik mühendisliği (feature engineering) , model seçimi ve hyperparametre adımları ayarlanmıştır.

Hyper parametreler:Bu projede manuel hyper parametreler ayarlanmıştır.

- n_estimators: Ağaç sayısı
- max_depth: Ağaç derinliği
- learning_rate: Öğrenme hızı
- subsample: Gözlem örnekleme oranı
- colsample_bytree: Özellik örnekleme oranı ile overfitting engelleme ve model başarısı için kullanılmıştır.

Feature set: Bu projede demografik bilgiler (Cinsiyet , fakülte , bölüm) ve davranışsal özellikler (kitap1,kitap2,kitap3) kullanılmıştır.

Best Model 2: MLP Modeli

MLP modeli öğrencilerin özelliklerine bağlı olarak çok katmanlı bir yapay sinir ağı olarak geliştirilmiştir. Özellik değişkenleri label encoding haline gelmiştir. Özellikler ölçeklendirilmiştir (StandartScaler).

Hyper parametreler: Tuning tekniği olarak GridSearchCV uygulanmıştır.

- `hidden_layer_sizes` = Gizli katman sayısı ve nöron sayıları
- `Activation` = Aktivasyon fonksiyonu (relu)
- `Solver` = Optimizasyon algoritması (adam)
- `Alpha` = L2 regularization katsayısı
- `learning_rate` = Öğrenme oranı
- `max_iter` = Maksimum epoch sayısı

Feature set: Cinsiyet,
Fakülte,
Bölüm,
Kitap-ID]

<u>Sıra</u>	<u>Uygulanan Model</u>	<u>Doğruluk (Acc)</u>	<u>Duyarlılık (Recall)</u>	<u>F1-Skoru (Macro)</u>
1	MLP (PyTorch - En Dengeli)	%75,67	0.517	0.516
2	XGBoost Classifier	%75,76	0.410	0.380
3	Gradient Boosting (Tuned)	%74,37	0.510	0.511
4	Deep MLP (PyTorch)	%74,40	0.478	0.465
5	Extra Trees (Tuned)	%73,25	0.410	0.381
6	ANN (Keras - Derin Öğrenme)	%76,00	0.410	0.380
7	Random Forest (Orijinal)	%73,21	0.400	0.366
8	Random Forest	%73,00	0.390	0.350
9	Logistic Regression (Baseline)	%73,07	0.390	0.345
10	Logistic Regression	%73,07	0.390	0.345
11	KNN (SVD - 20 Bileşen)	%71,88	0.380	0.342
12	LightGBM Classifier	%65,14	0.370	0.330
13	LSTM (Keras)	%65,00	0.330	0.310

Sonuçlar ve Değerlendirme -

Bu projede bir sonraki kitabı tahmin etmek için birden çok makine öğrenimi ve derin öğrenme modelleri kullanılmıştır. Verilerin dengesizliği veya verisetindeki eksiklikler kitap gibi projemizin dezavantajlarıdır.

Modeller doğruluk (accuracy) , makro F1 score , duyarlılık (recall) metrikler ile değerlendirilmiş olup En iyi sonuçları XGBoost modeli ve MLP modelleri vermiştir bu proje için aslında en iyi modellerin Bu sonuçlar , problemin doğrusal olmayan yapısının ve türetilmiş özelliklerin , çok katmanlı sinir ağları tarafından daha iyi öğrenildiğini göstermektedir.